

Inteligência Artificial para Robótica 2025/2026

Relatório Parte 1

Grupo 3

Diogo Nunes 104714

Guilherme Penedo 111222

João Antunes 111139

Luís Lourenço 110942

Arquiteturas dos Controladores

Foram utilizados três controladores distintos. O controlador Braitenberg recebe como entrada os dois sensores de chão e produz diretamente as velocidades dos motores através de uma arquitetura reativa com apenas 6 parâmetros evoluídos. O ANN Simples utiliza uma rede neuronal feedforward com arquitetura $2 \rightarrow 4 \rightarrow 2$, recebendo os sensores de chão como entrada e produzindo as velocidades dos motores, totalizando 22 parâmetros. O ANN Avançado utiliza uma arquitetura $5 \rightarrow 64 \rightarrow 32 \rightarrow 2$, incorporando os dois sensores de chão e três sensores de proximidade, com um total de 2530 parâmetros. Em ambas redes neuronais foi utilizada a função de ativação tanh nas camadas escondidas e na camada de saída.

Metodologia Experimental

Decidimos, para manter uniformidade, usar os mesmos parâmetros e penalizações e recompensas na função de fitness para o treino dos três controladores. Em cada execução foi registada a seed utilizada, permitindo a reprodução posterior dos resultados obtidos.

Para aumentar a capacidade de generalização e reduzir a dependência das condições iniciais, a posição e orientação do robot foram geradas aleatoriamente dentro de uma região centrada na arena. Cada indivíduo foi avaliado três vezes por geração (parâmetro Evaluation Runs = 3), e, em cada geração, todos os indivíduos foram testados exatamente nos mesmos três cenários, incluindo a configuração de obstáculos no caso do ANN Avançado. Na geração seguinte eram gerados novos cenários. Desta forma, garantiu-se uma comparação justa entre indivíduos dentro da mesma geração, promovendo simultaneamente a evolução de comportamentos robustos a diferentes condições do ambiente.

Algoritmo Evolutivo

Usamos um algoritmo genético com seleção por k-tournament, elitismo e crossover através de k-point crossover. A população evolui ao longo das gerações através da seleção dos indivíduos com melhor fitness, preservação dos melhores indivíduos e introdução de mutações aleatórias.

A evolução termina se durante STAGNATION_LIMIT gerações consecutivas não haver uma melhoria de MIN_IMPROVEMENT_PERCENT.

Parâmetro	Valor
Timestep	6.4
Population Size	50
Generations	50
Parents Keep (Elitismo)	5
Tournament Size	3
K-Point Crossover	3
Mutation Rate	0.15
Mutation Size	0.05
Range	5
Evaluation Time	100s
Evaluation Runs	3
Max Speed	9.53
Early Stopping	Ativado
Stagnation Limit	10
Min Improvement Percent	0.005
Seed	Aleatória, mas registrada
Line Buffer Size	300
Cell Size	0.02 (2cm)

Adicionalmente, usamos um buffer de tamanho 300, para alojar células de 2cm da linha preta (ou seja, 6m), para manter controle de possíveis revisitações em comportamentos de exploração local da linha.

Função de Fitness

O foco da nossa função de fitness foi incentivar distância percorrida na linha com ambos os sensores, de tal modo, só a contamos para os resultados quando o robot apresenta ambos sensores na linha, mas, para encorajar a descoberta desta, quando apenas um dos sensores estiver nela, penalizamos menos do que não estar sobre ela e damos uma recompensa minúscula. Isto permite diferenciar, estar simplesmente perdido na arena com estar perto da linha.

Para não penalizar o uso de marcha atrás para manobras, penalizamos apenas o uso prolongado dela, dando um período de tolerância.

Caso detetarmos que o robot revisitou uma das células da linha, quer esteja com um sensor ou dois na linha, para além de não ganhar recompensa, aplicamos uma penalização superior ao que possivelmente teria ganho.

Para desencorajar ainda mais estratégias de exploração local, foi mantido um histórico das células recentemente visitadas na linha. No final de cada avaliação é aplicada uma penalização proporcional ao rácio de revisitação e ao número total de células revisitadas.

Visto que a nossa penalização de revisit não incide sobre estar preso na mesma célula, decidimos adicionar também uma penalização para essa situação.

Aplicamos também uma penalização caso o robot perca a linha durante algum tempo, para encorajar percorrer a linha sem desvios ou atalhos, mas permitir pequenas manobras.


Para finalizar, penalizamos consistentemente por cada timestep que é detetada uma colisão.

Gráficos de convergência e métricas de exploração


Nota: considerámos distância percorrida apenas quando o robot tem ambos os sensores na linha, sendo que como já referido, a recompensa de percorrer a linha só com um sensor é muito menor que com ambos.

Braitenberg

Evolução da fitness e distância



Trajetória dos melhores indivíduos, por geração




Observações


O controlador Braitenberg conseguiu aprender a localizar e seguir a linha de forma consistente. Nas gerações iniciais observaram-se algumas trajetórias menos eficientes, refletidas em valores elevados de distância percorrida sem um aumento proporcional da fitness, indicando a presença de revisitações ou exploração local. Ao longo da evolução, a fitness apresentou uma tendência crescente e os comportamentos tornaram-se progressivamente mais estáveis. Apesar disso, o controlador revelou limitações quando analisado apenas pela distância percorrida com ambos os sensores sobre a linha, o que inicialmente sugeria um desempenho inferior às arquiteturas neurais. Para tentar melhorar esse comportamento, foi testada uma normalização das saídas para o intervalo $[-1,1]$, seguida de escalamento para a velocidade máxima dos motores, sem melhorias observáveis. No entanto, a análise posterior da distância percorrida com pelo menos um sensor sobre a linha revelou que o controlador era capaz de percorrer distâncias significativamente superiores, demonstrando que seguia a linha durante grande parte do percurso, embora frequentemente de forma descentralizada, com apenas um dos sensores a detetar a linha.

ANN Simples

Evolução da fitness e distância



Trajetória dos melhores indivíduos, por geração




Observações


O ANN Simples atinge rapidamente distâncias elevadas. Contudo, nas primeiras gerações observam-se diferenças significativas entre a distância percorrida e a função de avaliação obtida, indicando a existência de comportamentos de exploração local. À medida que a evolução progride, estes comportamentos são penalizados e substituídos por trajetórias mais próximas do seguimento ideal da linha.

ANN Advanced

Evolução da fitness e distância



Trajetória dos melhores indivíduos, por geração




Observações


O ANN Advanced apresentou um desempenho elevado ao longo da evolução. A combinação dos sensores de proximidade com uma arquitetura mais expressiva permitiu aprender comportamentos de seguimento de linha e desvio de obstáculos. Os picos apresentados nos gráficos resultam de em alguns cenários o robot não encontrar saída, apesar disso, atingiu várias vezes durante os três cenários a distância máxima em 100s.

Comparação coletiva

Evolução da fitness e distância



Trajetória do melhor indivíduo de cada controlador



Vídeos das trajetórias

- [Braitenberg](#)
- [ANN Simples](#)
- [ANN Advanced](#)

Validação

Cada benchmark foi realizado durante 300 episódios independentes de 100 segundos. Devido à existência de posições iniciais aleatórias e, no caso do ANN Advanced, obstáculos gerados aleatoriamente, os resultados podem variar entre execuções. Ainda assim, o número de episódios utilizado permite obter uma estimativa razoável do desempenho esperado de cada controlador.

Foram recolhidas métricas como a distância percorrida com um ou dois sensores, apenas com dois, número de colisões e foi calculada uma taxa de sucesso de distância e colisões, considerando como sucesso percorrer pelo menos 2 metros durante o episódio e ter menos de 6 colisões.

Controlador	Distância Média (2 sensores)	Distância Média (≥ 1 sensor)	Colisões Médias	Sucesso distância ($> 2m$)	Sucesso Colisões (≤ 5)
Braitenberg	3.81	10.91	50.61	95.0%	95.0%
ANN Simples	7.09	7.71	10.64	72.7%	92.0%
ANN Advanced	7.14	7.71	0.47	83.0%	97.7%

O controlador Braitenberg demonstrou elevada capacidade para permanecer próximo da linha ao longo do percurso, percorrendo em média 10.91 m quando considerado pelo menos um sensor sobre a linha. No entanto, a distância percorrida com ambos sensores ativos foi substancialmente inferior (3.81 m), indicando que grande parte do percurso é realizada numa posição menos centrada relativamente à linha. Adicionalmente, demonstra baixa robustez à perda da linha. Nos episódios em que perde o seguimento, tende a permanecer junto às paredes até ao final da avaliação, originando valores extremamente elevados de colisões. Embora estes casos representem apenas cerca de 5% dos episódios, são suficientes para aumentar significativamente a média de colisões observada.

O ANN Simples apresentou o melhor seguimento efetivo da linha. A reduzida diferença entre a distância medida com ambos os sensores ativos (7.09 m) e a distância medida com pelo menos um sensor ativo (7.71 m) indica que o robot permaneceu centrado sobre a linha durante grande parte da execução. Apesar de ocorrerem episódios ocasionais de perda da linha, o comportamento geral revelou-se robusto e com baixo número de colisões.

O ANN Advanced manteve uma diferença reduzida entre as duas métricas de distância, sugerindo um seguimento relativamente centrado da linha. Contudo, a presença de obstáculos gerados aleatoriamente introduziu cenários significativamente mais complexos, o que leva ocasionalmente ao robot ficar bloqueado ou incapaz de encontrar uma trajetória de saída antes do limite temporal do episódio. É também possível observar a utilização ocasional de pequenas manobras de marcha atrás durante a navegação. Este comportamento resulta da função de fitness apenas penalizar utilizações prolongadas de marcha atrás (mais de 15 timesteps consecutivos, cerca de 1s), permitindo manobras curtas úteis para desbloqueio e contorno de obstáculos.

Conclusões

Globalmente, os resultados mostram que as arquiteturas neuronais conseguem manter um seguimento da linha mais preciso e centrado do que o controlador Braitenberg. No entanto, o Braitenberg continua a demonstrar que abordagens reativas simples podem produzir comportamentos eficazes com um número muito reduzido de parâmetros. As suas limitações tornam-se mais evidentes quando são necessários comportamentos mais complexos ou maior robustez, uma vez que a arquitetura possui apenas ligações lineares entre sensores e atuadores, sem camadas escondidas ou mecanismos que permitam representar relações não lineares mais elaboradas.